

MINERAÇÃO DE DADOS EM SAÚDE · PNS 2019

Discretização das variáveis

Notebook 04 — a 7ª etapa do KDD aplicada ao estudo da artrite em idosos

Pedro Dias Soares

Orientador: Prof. Dr. Luis Enrique Zárate — PUC Minas (LICAP)

O que esta apresentação cobre

1

Contexto

Onde a discretização se encaixa no processo KDD do projeto

2

O conceito

O que é discretizar e por que é necessário (slide Introdução 12)

3

O método

O padrão de discretização dos artigos do orientador

4

O processo

As 6 etapas executadas no NB04, passo a passo

5

Os resultados

Cada faixa, cada gráfico e o que significam para o trabalho


6

O achado

A confirmação empírica do data leakage no Desenho 2

Onde a discretização se encaixa

O projeto segue o processo de Descoberta de Conhecimento em Bases de Dados (KDD). A discretização é a 7ª etapa — a ponte entre preparar os dados e minerá-los.




Você está aqui ▲ — a discretização recebe os dados limpos do NB03 e devolve um dataset pronto para o aprendizado.

O que é discretização?

“O processo de discretização transforma dados quantitativos em dados qualitativos — atributos numéricos viram atributos discretos com um número finito de intervalos.”

— definição do slide Introdução 12 do curso

Discretização na prática: de valor contínuo para faixa categórica



Exemplo real do projeto: a idade contínua (à esquerda) torna-se 3 faixas ordinais (à direita).

Por que discretizar? — 4 razões

Interpretabilidade

Algoritmos caixa-branca (Árvore, Naïve Bayes) — os usados pelo orientador — geram regras mais legíveis sobre faixas do que sobre números crus.

Redução de dimensionalidade

O slide trata a discretização como técnica de redução de dimensionalidade: menos valores distintos, espaço de busca menor.

Suavização de outliers

Valores extremos caem dentro de uma faixa e deixam de distorcer o modelo — argumento explícito do artigo de Hipertensão (CBIS'24).

Significado clínico

Faixas como as da OMS carregam sentido médico; um corte automático pela mediana (ex.: 13 anos) não teria — argumento do artigo de DPOC.

Tipos de discretização — e a nossa escolha

Não-supervisionada × Supervisionada

Usa ou não o rótulo da classe para definir cortes

Não-supervisionada (cortes por domínio, não pela classe)

Univariada × Multivariada

Uma variável por vez ou várias juntas

Univariada (cada variável tratada isoladamente)

Por largura × Por frequência

Intervalos iguais ou com nº de amostras igual

Largura por domínio + frequência (quantis) p/ escores

Estática × Dinâmica

Antes do modelo ou embutida nele

Estática (executada antes do NB05)

Coluna azul = a opção adotada neste trabalho, idêntica ao padrão dos 6 artigos do orientador analisados.

Como discretizamos — o padrão do orientador

FAIXAS POR DOMÍNIO

Cortes de fontes oficiais — OMS, Guia de Atividade Física BR 2021. Não-supervisionado, univariado. É a regra geral.

QUANTIS (exceção)

Só para escores compostos sem norma externa (Escore Inflamatório/Saudável). É o equal-frequency binning do slide.

ENTROPIA → SELEÇÃO

Entropia e correlação NÃO definem cortes; servem para selecionar/remover atributos — exatamente como nos artigos.

Convenção ordinal CAPTO: “risco crescente = nível maior” ($0 \rightarrow k$). Presente em todos os artigos analisados, favorece a leitura clínica das regras.

Opção A — uma única fonte de discretização

PROBLEMA

O NB03 já categorizava (Etapa 10) e o NB04 também iria discretizar.

→ *discretização em DOIS lugares — o mesmo risco de inconsistência que tivemos com os outliers.*

SOLUÇÃO (Opção A)

NB03 e NB03b entregam as contínuas numéricas.

O NB04 vira o único dono da discretização — com a fonte de cada corte e relatório JSON auditável.

→ *rastreável, sem duplicação, fiel ao KDD.*

Validação: notebook executado de ponta a ponta (nbclient) — 27 células sem erro; 3 bugs encontrados e corrigidos no processo.

As 6 etapas do Notebook 04

Inventário

1

Classifica colunas: contínuas a discretizar × já categóricas × numéricas sem faixa

Faixas por domínio

3

Aplica `pd.cut` com limites OMS / Guia BR — gera as colunas *_cat ordinais

Verificação

5

Prevalência da classe por faixa — a faixa discrimina?

Diagnóstico

2

Histograma de cada contínua com os cortes marcados (slide Introdução 11/12)

Quantis

4

`pd.qcut` nos escores compostos (sem norma externa)

Seleção & Export

6

Entropia+correlação sinalizam atributos; grava CSV + relatório JSON

De onde vem cada decisão da discretização

Etapa do NB04	Referência no SLIDE	Referência nos ARTIGOS do professor
Discretizar (transformar contínuo→faixa)	Introdução 12 — definição e tipos de discretização	Todos os 6 artigos categorizam variáveis antes do ML
Faixas por domínio (IMC, idade, ativ. física)	Introdução 12 — “intervalos pré-definidos” (não-superv.)	AVC, Depressão, DPOC, Hipertensão (OMS / Guia BR / NLM)
Quantis nos escores (equal-frequency)	Introdução 12 — “equal-frequency binning”	Rodrigues & Zárate (2024, TOC) — discretização por percentis
Suavização de outliers pela faixa	Introdução 14 — Análise de Outliers	Carvalho & Zárate (2024, HAS) — afirma explicitamente
Redução de dimensionalidade	Introdução 12 — discretização reduz dimensão	Cancella & Zárate (2025) — fusão/redução de atributos
Entropia + correlação p/ SELEÇÃO	Introdução 15 — Análise de Entropia	Gonçalves & Zárate (2024); Silva & Zárate (2024)
Ordinal “risco crescente = nível maior”	—	Método CAPTO — Zárate et al. (2023)

Nenhuma faixa foi escolhida ao acaso: cada etapa cita um slide do curso E um artigo do orientador que a respalda.

Dois desenhos de estudo discretizados

	Desenho 1 — Artrite pura	Desenho 2 — Artrite + comorbidades
Registros × atributos	4.826 × 46	8.357 × 54
Saudáveis (0)	4.332	4.332
Com artrite (1)	494	4.025
Razão de desbalanceamento	8,77 : 1 (severo → exige RUS)	1,08 : 1 (quase balanceado)
Features_cat criadas	5	5

O que isso significa: as mesmas regras de faixa (clínicas) servem aos dois desenhos. O NB04 detecta sozinho as colunas de cada um — por isso o Desenho 2 mantém as variáveis Q* (doenças) e o Desenho 1 não.

Por que apenas 5 foram discretizadas?

5 · DISCRETIZADAS

IMC, Idade (C008), Atividade física (P035),
Escore Inflamatório, Escore Saudável

As únicas contínuas COM critério de faixa — por isso só 5. Não é uma seleção.

26 · JÁ CATEGÓRICAS

Dummies One-Hot do NB03 (sexo, plano de
saúde, doenças Q*, consumo de sal...)

Já são categóricas — não há o que discretizar.

14 · NUMÉRICAS SEM FAIXA

Consumos alimentares brutos (dias/sem.), peso,
altura, Razão Inf/Saud...

Sem norma externa de corte (não há “OMS de dias de feijão”) → seguem numéricas.


Cada faixa, sua fonte e a referência teórica

Variável	Método	Faixas (níveis ordinais)	Fonte do corte	Referência teórica
IMC	domínio	Baixo·Normal·Sobrep.·Obesid.	OMS — IMC adultos	<i>Carvalho & Zárate (2024); Gonçalves & Zárate (2024)</i>
Idade (C008)	domínio	60–69 · 70–79 · 80+	Subdiv. do idoso	<i>Melo et al. (2024, DPOC); Carvalho & Zárate (2024)</i>
Ativ. física (P035)	domínio	Sedent.·Pouco·Mod.·Ativo	Guia Ativ. Física BR 2021	<i>Gonçalves & Zárate (2024); Carvalho & Zárate (2024)</i>
Escore Inflamatório	quantis	Q1 · Q2 · Q3 · Q4	Quartis da amostra	<i>equal-frequency binning — slide Introdução 12</i>
Escore Saudável	quantis	Q1 · Q2 · Q3 · Q4	Quartis da amostra	<i>equal-frequency binning — slide Introdução 12</i>

O que isso significa: as faixas por domínio replicam exatamente o que os artigos do orientador fazem (IMC-OMS, atividade física pelo Guia BR); os escores usam o equal-frequency binning definido no slide. Cada corte é, portanto, ancorado na literatura — não arbitrário.


Resultado 1 — distribuição do IMC em faixas

Discretização por domínio: IMC em faixas da OMS



O que isso significa: Sobrepeso + Obesidade dominam os dois desenhos (D1: 2.328/4.826; D2: 4.673/8.357). A faixa da OMS preserva o sentido clínico — um corte automático pela mediana não diria nada ao médico.

Resultado 2 — a faixa de IMC carrega risco?



Leitura do gráfico

No Desenho 2, a prevalência de artrite sobe a cada faixa de excesso de peso:


Normal 38% → Sobrepeso 50% → Obesidade 67%.

(A faixa “Baixo peso” foge da tendência — 41% —, mas tem só 205 pessoas, o que explica a oscilação.)

Isso é o que a literatura médica espera — a faixa da OMS, mesmo não-supervisionada, capturou um gradiente de risco real.

O que isso significa: a discretização não destruiu informação — preservou a relação dose-resposta entre obesidade e artrite. É a prova de que o corte por domínio foi uma boa escolha.

Resultado 3 — a faixa etária carrega risco?



Leitura do gráfico

A faixa 80+ é a de maior risco nos dois desenhos:

Desenho 1: 9,7% · 9,5% · 15,2% (salto no 80+)


Desenho 2: 43% · 54% · 57% (crescente, +14 pp)

A subdivisão 60–69 / 70–79 / 80+ separou grupos de risco distintos dentro da própria terceira idade — algo que a idade crua não evidenciaria.

O que isso significa: discretizar o idoso em 3 faixas (em vez de manter a idade crua) revelou que o grupo 80+ é claramente o mais afetado — uma informação acionável para o artigo.

Resultado 4 — as faixas discriminam a classe?

Desenho 2 (Artrite + comorbidades) — prevalência por faixa



O que isso significa: o vermelho (artrite) cresce de forma clara nas faixas de IMC; nos escores por quartil o padrão é mais irregular (ver slide seguinte). Proporções diferentes entre níveis = faixa informativa — “reduzir a perda de informação é o objetivo da discretização” (slide).

Dois pontos que merecem atenção

1 · Escore Inflamatório por quartis NÃO mostrou gradiente limpo



No Desenho 2 a prevalência por quartil foi 65% → 56% → 33% → 37% — sem monotonia. **Por quê:** o escore é uma soma de hábitos cortada por quartis da amostra (sem norma clínica). É uma limitação a discutir — e um argumento para, no futuro, buscar um corte com referência externa.

2 · A faixa “Sedentário” (P035 = 0) ficou vazia

Nenhum registro caiu no nível 0 de atividade física. **Por quê:** quem não pratica já foi tratado pelo skip pattern no NB03 (via P034). Os que chegaram ao NB04 têm $P035 \geq 1$ dia. Não é bug — é coerência do pipeline, mas vale registrar para não confundir na leitura.

Resultado 5 — entropia + correlação revelam o leakage

Seleção por correlação — confirmação empírica do data leakage (Desenho 2)



Desenho 1: correlação máxima com o alvo = 0,14. **Desenho 2:** hipertensão (Q00201) atinge 0,70 e foi sinalizada como “alta_corr_alvo” — uma variável-consequência usada para definir o próprio controle “saudável”.

O que o data leakage significa para o trabalho

O problema

No Desenho 2, o controle “saudável” foi definido como quem NÃO tem nenhuma doença Q*. Logo, hipertensão (uma Q*) prediz o alvo quase trivialmente — é consequência da definição, não causa da artrite.

O conceito (slide)

O slide “Consequência vs. Causalidade” alerta: usar variáveis-consequência leva a modelos “Naïve”, com acurácia inflada e sem valor explicativo real.

A evidência

A entropia+correlação do NB04 quantificou isso: 0,70 vs. 0,14. O número confirma, empiricamente, o risco que era só teórico.

A ação no NB05

Treinar Modelo A (com Q*) e Modelo B (sem Q*) — análise de sensibilidade. Comparar mostra quanto da performance vinha do leakage.

Cada decisão ancorada na literatura

IMC / Idade / Ativ. física por faixa de domínio

AVC, Depressão, DPOC, HAS — todos usam OMS / Guia BR

Discretização suaviza outliers

Artigo de Hipertensão (CBIS'24), seção de preparação

Entropia + correlação só para selecionar atributos

AVC e Depressão — etapa “Remoção por Entropia/Correlação”

Hipertensão = variável-consequência (leakage)

Slide Consequência vs. Causalidade + aviso do NB03b

Ordinal “risco crescente = nível maior”

Método CAPTO (Zárate et al., 2023), comum a todos

Fundamentação teórica

Slides da disciplina (Prof. Zárate)

- Introdução 6 — O Processo (KDD). Etapas de Fayyad et al. (1996).
- Introdução 12 — Preparação dos dados. Definição, tipos e métodos de discretização (largura, frequência, supervisionada).
- Introdução 14 — Análise de Outliers.
- Introdução 15 — Análise de Entropia (seleção de atributos).
- Consequência vs. Causalidade — risco de variável-consequência.

Artigos do orientador (PNS 2019)

- GONÇALVES, L. F. C.; ZÁRATE, L. E. Comparação de perfis de AVC entre idosos e adultos. SBBB Companion, 2024.
- SILVA, P. H. R.; ZÁRATE, L. E. Caracterização da depressão em adultos no Brasil. SBBB Companion, 2024.
- CANCELLA, L. F. R.; ZÁRATE, L. E. Perfil Artrite-Depressão. SBBB Companion, 2025.
- RODRIGUES, A. P. C.; ZÁRATE, L. E. Fatores socioambientais no TOC. SBBB, 2024.
- MELO, R. P. N.; GOMES, M. P. S.; ZÁRATE, L. E. ML no diagnóstico de DPOC. J. Health Inform. (CBIS), 2024.
- CARVALHO, N. M.; GOMES, M. P. S.; ZÁRATE, L. E. Mineração no diagnóstico de hipertensão. J. Health Inform. (CBIS), 2024.
- ZÁRATE, L. E. et al. CAPTO — método de entendimento de domínio. Concilium, v.23, p.922–941, 2023.

O que a discretização entregou

1 2 datasets prontos para o ML

4.826×46 e 8.357×54 features. A discretização criou 5 novas variáveis categóricas ordinais (IMC, idade, ativ. física e 2 escores).

2 Faixas com sentido clínico e gradiente de risco

IMC e idade confirmaram dose-resposta (obesidade 67%, 80+ 57% no Desenho 2).

3 Cortes rastreáveis e citáveis

Cada faixa tem fonte (OMS / Guia BR) no JSON — base direta da seção de Métodos.

4 Leakage comprovado com número

Hipertensão 0,70 vs. 0,14 — sustenta a análise de sensibilidade (Modelo A vs B).

Próximo passo → NB05 (Modelagem): Reg. Logística · Árvore · Random Forest · RUS na CV · F1-macro · Modelo A (com Q*) vs B (sem Q*).