

MINERAÇÃO DE DADOS EM SAÚDE · PNS 2019

Discretização das variáveis

Notebook 04 — a 7ª etapa do KDD aplicada ao estudo da artrite em idosos brasileiros

Pedro Dias Soares · Orientador: Prof. Dr. Luis Enrique Zárate — PUC Minas (LICAP)

O que esta apresentação cobre

1

Contexto

Onde a discretização se encaixa no processo KDD do projeto

2

Método

O padrão de discretização do orientador e a arquitetura "Opção A"

3

Faixas por domínio

IMC, idade, atividade física e álcool — cortes oficiais e seus resultados

4

Plano cartesiano

Frequência alimentar em 4 quadrantes (Ribeiro & Zárate, 2019)

5

Anti-leakage

Comorbidades como filtro de corte, não como variáveis do modelo

6

Síntese

Dois datasets discretizados e prontos para o aprendizado de máquina

Onde a discretização se encaixa




Ideia central: a discretização é a etapa de transformação que prepara os dados contínuos para os algoritmos caixa-branca usados pelo orientador.

O que é discretização?

“Transforma dados quantitativos em qualitativos — atribuindo a valores contínuos um número finito de intervalos (faixas).” — slide Introdução 12 do curso

Discretização na prática: de valor contínuo para faixa categórica



Exemplo real do projeto: a idade contínua (à esquerda) torna-se 3 faixas ordinais — 60–69 · 70–79 · 80+ (à direita).

Por que discretizar? — 4 razões

1. Interpretabilidade

Algoritmos caixa-branca (Árvore, Naïve Bayes) geram regras mais legíveis sobre faixas do que sobre números crus.

2. Redução de dimensionalidade

Menos valores distintos por atributo — o slide trata a discretização como técnica de redução.

3. Suavização de outliers

Valores extremos caem dentro de uma faixa, sem distorcer o modelo (artigo de Hipertensão, CBIS'24).

4. Aderência ao padrão do orientador

Os 6 artigos do LICAP sobre a PNS discretizam por faixas — replicamos o método.

Tipos de discretização — e a nossa escolha

Não-supervisionada × Supervisionada

Usa ou não o rótulo da classe para definir cortes.

Nossa escolha: NÃO-supervisionada — cortes por domínio, nunca pela classe.

Univariada × Multivariada

Uma variável por vez, ou várias em conjunto.

Univariada — exceção: o plano cartesiano cruza 2 escores de frequência.

Estática × Dinâmica

Cortes fixos a priori ou ajustados pelo algoritmo.

Estática — faixas definidas antes da modelagem, auditáveis.

Como discretizamos — o padrão do orientador

FAIXAS POR DOMÍNIO

A regra

Cortes de fontes oficiais — OMS, Guia de Atividade Física BR 2021, NIAAA. Não-supervisionado e univariado.

PLANO CARTESIANO

Frequência alimentar

Os 2 escores de frequência viram eixos de um plano → 4 quadrantes (Ribeiro & Zárate, 2019).

QUANTIS

A exceção

Equal-frequency só para escores sem norma externa E fora do plano. Hoje não utilizado.

Importante: entropia e correlação aparecem apenas para SELECIONAR/remover atributos — nunca para definir os cortes (mantemos a discretização não-supervisionada).

Opção A — uma única fonte de discretização

O PROBLEMA

O NB03 já categorizava (Etapa 10) e o NB04 também iria discretizar.
→ discretização em **dois lugares**, risco de divergência e retrabalho.

A SOLUÇÃO (Opção A)

NB03 e NB03b entregam as contínuas **numéricas**.
O NB04 é o **único dono** da discretização — uma fonte, rastreável.
Mesma lógica que isolou o tratamento de outliers.

Resultado: sem discretização duplicada; cada corte tem uma origem única e auditável no NB04.

As etapas do Notebook 04

1

Inventário

Classifica colunas: contínuas a discretizar × já categóricas × removíveis

2

Faixas por domínio

Binning não-supervisionado com fontes oficiais (OMS, Guia BR, NIAAA)

3

Plano cartesiano

Frequência alimentar resumida em 4 quadrantes ordinais

4

Verificação

Prevalência da classe por faixa — checa perda de informação

5

Seleção

Entropia + correlação sinalizam atributos (não definem cortes)

6

Exportação

Datasets discretizados + relatório JSON de rastreabilidade

Mesmas regras de faixa, duas coortes

DESENHO 1 · Artrite pura

494

casos (artrite isolada)

vs 4.332 saudáveis · razão 8,77:1

Caso limpo, sem comorbidades — triangulação.

DESENHO 2 · Com comorbidades

4.025

casos (qualquer combinação)

vs 4.332 saudáveis · razão 1,08:1

Idoso real — mais casos e poder estatístico.

Anti-leakage (detalhe na Parte 5): as comorbidades definem QUEM entra na coorte (filtro), mas NÃO entram como features — o modelo não as enxerga.

O que é discretizado — e por quê

6

DISCRETIZADAS

IMC, Idade, Atividade física, Consultas, Álcool (só D1) e o Padrão Alimentar (plano)

26

JÁ CATEGÓRICAS

Variáveis nominais/ordinais — Label Encoding e One-Hot (passam direto)

+

REMOVIDAS

Contínuas redundantes (peso/altura $\subset$ IMC; itens $\subset$ plano) e comorbidades-filtro


Leitura: só as contínuas COM critério de faixa são discretizadas — não é uma seleção arbitrária, e nada é escolhido ao acaso.

Cada faixa, sua fonte e a referência

VARIÁVEL	FAIXAS	FONTE / REFERÊNCIA
IMC	4 faixas	OMS — classificação de IMC para adultos
Idade (C008)	3 faixas	Subdivisão etária do idoso (60–69 · 70–79 · 80+)
Atividade física (P035)	4 faixas	Guia de Atividade Física para a População Brasileira (2021)
Consultas médicas (J012)	4 faixas	Intensidade de uso de serviços de saúde (pragmática)
Álcool/ocasião (P029)	3 faixas	NIAAA — binge ≥5 doses (só D1; ~71% imputado → baixa confiança)
Padrão alimentar	4 quadrantes	Ribeiro & Zárate (2019) — plano cartesiano de frequência


Distribuição do IMC em faixas

Discretização por domínio: IMC em faixas da OMS




O que isso significa: Sobrepeso + Obesidade dominam os dois desenhos — a discretização preserva o sinal antropométrico.

A faixa de IMC carrega risco?



O que isso significa: a prevalência de artrite sobe a cada faixa de excesso de peso — a discretização não destruiu a relação dose-resposta.


A faixa etária carrega risco?



O que isso significa: a faixa 80+ é a de maior risco nos dois desenhos — discretizar o idoso em 3 faixas revela o gradiente que a idade crua escondia.

As faixas discriminam a classe?

Desenho 2 (Artrite + comorbidades) — prevalência por faixa



O que isso significa: o vermelho (artrite) cresce de forma clara nas faixas de IMC e idade — as faixas mantêm o poder de separar as classes.

O plano cartesiano

Os escores de frequência alimentar não têm norma externa (não existe “OMS do escore”). **Em vez de quartis, seguimos Ribeiro & Zárate (2019): combinar os dois escores num plano e ler os quadrantes.**

Do escore por quartis ao plano cartesiano

O PROBLEMA (quartis)

Discretizar cada escore por **quartis** não deu gradiente limpo: no D2 a prevalência foi **65→56→33→37%** (sem monotonia).

Quartis não têm significado clínico e tratam os escores de forma **isolada**, perdendo a interação dieta protetora × pró-inflamatória.


A SOLUÇÃO — Ribeiro & Zárate (2019)

O grupo do próprio orientador (LICAP) combina **Blocks de frequência** via **produto cartesiano**.

Aplicamos à alimentação: os dois escores viram os **eixos de um plano**, e o cruzamento gera 4 quadrantes ordinais interpretáveis.

REFERÊNCIA RIBEIRO, C. E.; ZÁRATE, L. E. Classifying longevity profiles through longitudinal data mining. *Expert Systems with Applications*, v. 117, p. 75–89, 2019.


Os 4 quadrantes do consumo alimentar



corte: MEDIANA de cada eixo (não-supervisionado)

Como ler: eixo X = consumo pró-inflamatório, eixo Y = consumo protetor; cada eixo cortado na MEDIANA. O código 0–3 vai do Protetor ao Pró-inflamatório (risco crescente teórico).


Onde caem os idosos nos dois eixos



Como ler: cada ponto é um idoso (vermelho = artrite, verde = saudável); as linhas tracejadas são as medianas. O corte por mediana mantém os 4 quadrantes equilibrados.


O que cada quadrante revela

Prevalência de artrite por quadrante alimentar — gradiente LIMPO porém INVERTIDO
(quem consome mais pró-inflamatório aparece com MENOS artrite — ver limitação)



Atenção — gradiente invertido: o gradiente é limpo e monotônico, mas na direção OPOSTA ao rótulo (Pró-inflamatório tem MENOS artrite). Herda o artefato do Escore Inflamatório (imputação 57–74% + causalidade reversa). Mantido e documentado como limitação.

Entropia + correlação flagram o vazamento



O problema: no D2, o controle “saudável” não tem nenhuma doença Q*; logo a hipertensão (Q00201) atinge correlação 0,70 com o alvo (vs 0,14 no D1) — separa as classes de forma circular.

Comorbidades viram filtro, não feature

ANTES — vazava

Controle definido como **sem nenhuma das 14 doenças**.

Comorbidades **sempre 0 nos controles**: qualquer $Q^* = \text{Sim}$ predizia artrite com erro zero (correlação 0,70).

AGORA — filtro, não feature

As 13 comorbidades do filtro foram **removidas das features** (11 colunas no D2); servem só para selecionar a coorte.

A coorte **não mudou**. Q084 (coluna), que não era do filtro e varia nos controles, permanece como feature legítima.

O que isso significa: o modelo nunca enxerga as comorbidades — o vazamento circular desaparece. D1 e D2 diferem só na coorte de casos (pura × com comorbidades).

Cada decisão ancorada na literatura



IMC / Idade / Atividade física por faixa de domínio

AVC, Depressão, DPOC, HAS — todos usam OMS / Guia BR



Plano cartesiano de frequência alimentar

Ribeiro & Zárate (2019), Expert Systems with Applications



Discretização suaviza outliers

Artigo de Hipertensão (CBIS'24), seção de preparação



Entropia/correlação para seleção; “Consequência × Causalidade”

Slides da disciplina — guiam a poda e a leitura do leakage

Fundamentação teórica

Slides da disciplina (Prof. Zárate)

Introdução 6 — O Processo (KDD), etapas de Fayyad et al. (1996). · Introdução 12 — Preparação dos Dados (discretização). · Consequência × Causalidade.

Artigos do orientador (LICAP / PNS 2019)

RIBEIRO, C. E.; ZÁRATE, L. E. Classifying longevity profiles through longitudinal data mining. *Expert Systems with Applications*, v. 117, p. 75–89, 2019.

GONÇALVES, L. F. C.; ZÁRATE, L. E. et al. Estudos de AVC, Depressão, DPOC e Hipertensão em idosos com a PNS 2019 (SBBD/CBIS).

Organização Mundial da Saúde — classificação de IMC. · Guia de Atividade Física para a População Brasileira (2021). · NIAAA — binge drinking.

SAEB, S. et al. The need to approximate the use-case in clinical machine learning. *GigaScience* 6(5), 2017.

O que a discretização entregou

D1 · Artrite pura

4.826 × 33 registros × features

Label 494 / 4.332 · 100% categórico, sem comorbidades-leak

D2 · Com comorbidades

8.357 × 31 registros × features

Label 4.025 / 4.332 · 100% categórico, sem comorbidades-leak

1. 6 variáveis ordinais novas

IMC, Idade, Atividade física, Consultas, Álcool (D1) e Padrão Alimentar (plano cartesiano).

2. Frequência alimentar resumida

2 escores → 1 feature interpretável de 4 quadrantes (Ribeiro & Zárate, 2019).

3. Sem data leakage

Comorbidades viram filtro de corte; o modelo não as enxerga.

4. Pronto para o NB05

Balanceamento via RUS na validação cruzada (F1-macro).